

112 AI Trainer

Тренажёр диспетчера ДДС

Руководство по развёртыванию и эксплуатации сервера

T112 ПД 02

Программная версия v1.0

Разработчик и ответственный за документацию

Кодзаев Николай Петрович

28.09.2026

A handwritten signature in black ink, consisting of stylized, overlapping loops and strokes, likely representing the initials and surname of the author.

Аннотация

Руководство предназначено для системного администратора. Описывает установку нового локального стенда, адресацию, подготовку моделей и сертификатов, запуск сервисов, резервное копирование, обновление и диагностику. Рабочие данные существующего стенда не требуется пересоздавать.

Содержание

1 Общие сведения о программе	3
2 Структура программы и сетевые связи	3
3 Подготовка адреса сервера	4
4 Получение комплекта и зависимостей	5
5 Настройка локального ИИ и ресурсов.....	5
6 Настройка HTTPS и SIP	7
7 Сборка и первый запуск.....	7
8 Проверка программы.....	8
9 Резервное копирование и восстановление	8
10 Обновление и остановка	9
11 Дополнительные возможности	10
12 Сообщения системному программисту.....	10

1 Общие сведения о программе

Сервер обслуживает веб-интерфейс, учебные сессии, телефонные диалоги и хранение результатов. Все модели работают локально. Видеокарта не обязательна: без неё языковая модель работает на CPU, с ней — ускоряется автоматически (LLM_DEVICE=auto). Облачные ключи не нужны. Ученикам не нужно устанавливать Docker, Python или Ollama.

Для ИИ-сервера в ТЗ указаны процессор Intel Core i7 или Xeon либо аналог от шести ядер, RAM от 32 ГБ и NVMe SSD от 512 ГБ. Фактический объём свободного места рассчитывают с учётом образов, моделей, карты, записей и резервных копий. Оставьте свободное место для записей и резервных копий.

Поддерживаемая схема установки: Linux с Docker Engine и Compose либо Windows с Docker Desktop в режиме Linux-контейнеров. Нужны Git, Python версии 3.12 или выше, OpenSSL и Ollama. Compose должен поддерживать !override, то есть версию не ниже 2.24.4. Команды ниже выполняются из корня репозитория. На Linux команда python при необходимости заменяется на python3.

2 Структура программы и сетевые связи

Frontend принимает HTTPS-запросы на порту 3000 и передаёт их Backend. Backend обращается к базе и локальному Ollama. Voice связывает Asterisk с распознаванием, моделью и синтезом. Служебные порты не публикуются для учеников.

Направление	Протокол и порт	Назначение
ПК ученика → сервер	HTTPS TCP 3000	Сайт
IP-телефон → сервер	SIP TLS TCP 5061	Регистрация и управление звонком
Телефон ↔ сервер	SRTP UDP 20000–20199 на сервере	Звуковой поток
Контейнеры → Ollama	HTTP TCP 11434 в доверенном сегменте	Локальный инференс

Направление	Протокол и порт	Назначение
Backend ↔ база	TLS TCP 5432 внутри Compose	Учебные данные
Сервисные соединения	HTTPS 8000 и 8001, ARI 8089	Внутреннее взаимодействие

Ollama не имеет публичного пользовательского входа в этой схеме. Его порт разрешают только серверным компонентам, не всей ученической сети. Для удалённого узла моделей требуется отдельная защищённая транспортная конфигурация: текущий адаптер обычно обращается по HTTP внутри доверенной среды.

3 Подготовка адреса сервера

Назначьте серверу постоянный IP. Далее во всех примерах используется 192.168.10.10, имя `trainer12.lan`, подсеть рабочих мест 192.168.10.0/24. Это пример: до выполнения команд замените его своим адресом. Одинаковые фактические значения должны попасть в сертификаты, переменные среды, правила межсетевого экрана и карточку подключения ученика.

Если локального DNS нет, используйте IP во всех настройках. В этом случае адрес сайта имеет вид `https://192.168.10.10:3000`. Адрес 127.0.0.1 на компьютере ученика обозначает сам компьютер ученика, а не сервер.

Разрешите указанные внешние порты только из учебной подсети. Не открывайте наружу PostgreSQL, ARI, Voice и Ollama. Проверьте синхронизацию времени сервера и рабочих мест. Сертификаты с истёкшим сроком или другим именем не следует обходить через предупреждение браузера.

4 Получение комплекта и зависимостей

На подготовительной машине с доступом к сети получите исходники и зафиксируйте нужную версию. Для приватного репозитория нужен доступ, выданный владельцем.

```
git clone https://github.com/kolloko2/112-ai-trainer.git
cd 112-ai-trainer
git checkout v1.0
python -m venv .venv
```

Активируйте среду: Windows — `.venv\Scripts\Activate.ps1`; Linux — `source .venv/bin/activate`. Установите зависимости служебных скриптов. Полный список приведён в `deploy/requirements.txt`; основной код устанавливается внутрь контейнеров при сборке.

```
python -m pip install -r deploy/requirements.txt
python deploy/prepare.py
```

`prepare.py` создаёт `.env.docker` с уникальными секретами и SIP-аккаунтами 201–220, а также ключ резервного копирования. Он не перезаписывает существующий ENV. Не запускайте подготовку заново для смены адреса работающего сервера: изменяйте существующие настройки после резервного копирования.

Сопоставление номера телефона и индивидуального пароля хранится в `SIP_ACCOUNTS_JSON` внутри `.env.docker`. Разрешённые номера перечислены в `ALLOWED_EXTENSIONS`. Администратор выдаёт рабочему месту только его номер и пароль по защищённому каналу, а не весь файл конфигурации. Ведите таблицу «ученик — АРМ — SIP-номер»; преподаватель использует номера из этой таблицы при подготовке занятия.

5 Настройка локального ИИ и ресурсов

В защищённом редакторе откройте `.env.docker`. Для новой поставки задайте следующие несекретные параметры; сгенерированные пароли сохраните без изменений.

```
LLM_PROVIDER='ollama'
LLM_PROFILE='standard'
OLLAMA_URL='http://host.docker.internal:11434'
```

```
PHONE_LLM_MODEL='qwen3:4b-instruct-2507-q4_K_M'
PHONE_LLM_THREADS='6'
OPENROUTER_API_KEY=''
INSTALL_LOCAL_PROVIDERS='true'
INSTALL_SILERO='true'
STT_PROVIDER='hybrid'
STT_MODEL='/models/vosk-model-small-ru-0.22'
STT_FINAL_MODEL='/models/sherpa-onnx-nemo-ctc-giga-am-v2-russian-2025-04-19'
TTS_PROVIDER='silero'
TTS_VOICE='/models/v5_5_ru.pt'
```

Если служебные скрипты запускаются на хосте, локальный Ollama должен быть доступен по адресу хоста; `host.docker.internal` используется контейнерами. Для загрузки моделей сначала проверьте `python tools/fetch_llm.py --help` и задайте доступный с хоста URL. Альтернативный прямой способ загрузки:

```
ollama pull qwen3:8b
ollama pull qwen3:4b-instruct-2507-q4_K_M
python tools/fetch_models.py
python -m pip install "osmium>=4,<5"
python tools/prepare_regional_map.py --download
```

Весы и карта не входят в Git. Для закрытого контура их переносят с подготовительной машины вместе с лицензиями. При старте разговора скачивание из Интернета не требуется. Ollama должен слушать интерфейс, доступный контейнерам; ограничьте доступ межсетевым экраном. На Linux проверьте разрешение `host.docker.internal` согласно `extra_hosts` в Compose, а не подставляйте адрес учебного ПК.

Переменная `OLLAMA_HOST` относится к процессу Ollama на хосте, а не только к `.env.docker`. Для отдельного запуска на Windows сначала завершите фоновый Ollama, затем в выделенном PowerShell задайте `$env:OLLAMA_HOST="0.0.0.0:11434"` и выполните `ollama serve`. На Linux для системной службы задайте `Environment="OLLAMA_HOST=0.0.0.0:11434"` в её секции Service и перезапустите службу штатными средствами. При таком прослушивании межсетевой экран обязан запрещать доступ к 11434 от учебных и внешних узлов; доступ оставляют только контейнерам сервера. После перезагрузки настройка должна сохраняться в конфигурации службы.

6 Настройка HTTPS и SIP

Задайте в `.env.docker`:

```
WEB_BIND_ADDRESS='192.168.10.10'
SIP_BIND_ADDRESS='192.168.10.10'
SIP_EXTERNAL_ADDRESS='192.168.10.10'
TLS_ALLOWED_ORIGINS='https://192.168.10.10:3000,https://trainer112.lan:3000'
SIP_LOCAL_NET='172.16.0.0/12'
```

`SIP_LOCAL_NET` задаёт сети контейнеров для принятия решений NAT. Уточните диапазон фактической Docker-сети; не добавляйте туда автоматически ученическую подсеть. `SIP_EXTERNAL_ADDRESS` должен быть доступным телефону адресом сервера.

Для нового контура выпустите сертификаты с фактическими DNS и IP. OpenSSL должен быть доступен в PATH.

```
python deploy/tls/generate.py --dns-san trainer112.lan --ip-san 192.168.10.10
python deploy/tls/validate_overlay.py
```

Генератор отказывается заменять существующие ключи и сертификаты. При смене адреса действующего стенда подготовьте новый комплект отдельно и запланируйте замену; не удаляйте текущий CA ради быстрого запуска. На ПК учеников передают только `deploy/tls/ca/ca.cert.pem` и проверяют его отпечаток. Закрытый ключ CA на рабочие места не передают.

7 Сборка и первый запуск

```
python deploy/manage.py --tls build
python deploy/manage.py --tls up
python deploy/manage.py status
```

При первом запуске оставьте `PIPELINE_MODE='spike'` и `TOPOLOGY_VERIFIED='false'`. Подключите отдельный проверочный телефон, подтвердите регистрацию и двустороннюю передачу звука. Проверку выполняют на свободном учебном номере, не вытесняя телефон ученика. Порядок медиа-пробы описан в `voice/README.md`.

После проверки установленных моделей и медиа-тракта задайте `PIPELINE_MODE='conversation'` и `TOPOLOGY_VERIFIED='true'`, затем повторите `python deploy/manage.py --tls up`.

Откройте <https://192.168.10.10:3000/login>. В пустой базе форма первоначальной настройки позволяет создать администратора. Придумайте уникальный пароль; затем создайте учётные записи преподавателей и учеников. В существующей базе используйте действующего администратора: повторная начальная настройка не нужна.

8 Проверка программы

Проверьте здоровье контейнеров, наличие моделей и регистрацию телефона:

```
python deploy/check_bundle.py
ollama ps
docker compose --env-file .env.docker exec asterisk asterisk -rx "pjsip show contacts"
```

Устройство телефонной модели задаётся LLM_DEVICE (auto, cpu, gpu) или в кабинете администратора; ollama ps показывает фактическое размещение (CPU или GPU). При смене устройства Backend перезапускается и заново загружает модель. Выполните контрольное занятие: преподаватель назначает карточку ДДС, ученик принимает её, вызывает дежурного через сайт, получает звонок на телефон, передаёт сведения и завершает реагирование. Проверьте сохранение отчёта после повторного входа.

Проверьте карту по адресу внутри установленного региона. Затем отключите внешний доступ в Интернет и повторите вход, карту и короткий диалог.

9 Резервное копирование и восстановление

В TLS-профиле запускается backup-worker. Ежедневное расписание задаётся в техническом кабинете администратора; час хранится в UTC. Резервирование работает в Docker и не зависит от планировщика Windows. Копии .t112 шифруются AES-256-GCM. Ключ хранится отдельно в deploy/private/backup.env. Утрата ключа делает архивы недоступными.

Сохраняйте копии и ключ отдельно вне сервера. Модели и региональную карту храните как отдельные поставочные ресурсы:

ежедневная копия их не включает. Наблюдайте за свободным местом — автоматическое удаление всех старых копий не предполагается.

Восстановление выполняют на изолированном пустом стенде, а не поверх работающей базы. Сначала сверяют архив и ключ, расшифровывают в отдельный защищённый каталог, читают манифест, восстанавливают дампы и файловые тома согласованной версии. Команда расшифровки:

```
python deploy/full_backup.py decrypt --source /backup/copy.t112 --output
/restore/copy.tar.gz
```

Путь и расширение результата сверяйте с `--help` и составом архива. Затем штатным `pg_restore` загружают дампы в пустую базу с правильным владельцем и восстанавливают записи и `outbox`. До переключения пользователей проверяют вход, карточку, отчёт и доступность записей.

10 Обновление и остановка

До обновления завершите занятия, сохраните резервную копию, текущий коммит и образы. Получите новую версию, ознакомьтесь с изменениями конфигурации, пересоберите только необходимые образы и запустите прежний профиль. Не заменяйте рабочий ENV файлом из чужого стенда.

```
python deploy/manage.py stop
python deploy/manage.py --tls build
python deploy/manage.py --tls up
```

Команда `stop` сохраняет тома. Не используйте `docker compose down -v` при обычном обновлении: этот параметр удаляет постоянные тома. При неудаче откатите приложение на сохранённые образы; совместимость схемы данных проверяется отдельно.

Для переноса подготовленного комплекта выполните `python deploy/manage.py export-images` и загрузите архив на целевой машине командой `docker image load -i <архив>`. Отдельно перенесите код, `deploy/models`, `deploy/maps` и организуйте собственные секреты и сертификаты целевого контура.

11 Дополнительные возможности

Для мониторинга хоста и разрешённых операций Voice/Asterisk запускается `python deploy/ops_worker.py`. На Linux его оформляют службой `systemd` с рабочим каталогом репозитория. Доступ к Docker является привилегированным; служебная учётная запись не должна использоваться учениками. Резервные копии продолжают обслуживаться контейнером `backup-worker`.

Профиль `--cluster` добавляет балансировщик и две реплики Backend с координацией через PostgreSQL. Профиль масштабирует прикладной сервер; голосовые модели и БД обслуживаются отдельно. Подключение каталога LDAPS описано в `docs/DIRECTORY_AUTH.md`. Локальные роли назначаются администратором.

12 Сообщения системному программисту

Признак	Проверка и действие
Deployment ENV already exists	Используйте существующую конфигурацию; не удаляйте её
Missing key или certificate	Выполните подготовку ключа и сертификатов нового стенда
Браузер не доверяет сайту	Сверьте имя SAN, срок и доверие публичному СА
Телефон не зарегистрирован	Сверьте TLS 5061, номер, пароль, сервер и правила сети
Есть звонок, нет звука	Сверьте SRTP, RTP-диапазон, NAT, гарнитуру и модели
ИИ не отвечает	Проверьте Ollama с контейнерной стороны, наличие весов и RAM
Карта недоступна	Проверьте <code>deploy/maps/regional.sqlite</code> и права чтения
Нет свежей копии	Проверьте <code>backup-worker</code> , расписание UTC, ключ и место на диске