

112 AI Trainer

Тренажёр диспетчера ДДС

Описание программного обеспечения и технологий

T112 ПД 06

Программная версия 9fb10f8

Разработчик и ответственный за документацию

Кодзаев Николай Петрович

28.09.2026

A handwritten signature in black ink, appearing to be 'N. P. Kodzaev', written in a stylized, cursive manner.

Аннотация

Документ предназначен для разработчика и специалиста по сопровождению. Содержит архитектуру, назначение технологий, модели ИИ, форматы обмена, зависимости, правила расширения и границы поставочного профиля.

Содержание

1 Общие сведения	3
2 Функциональная архитектура	3
3 Языковые и речевые модели	4
4 Основные библиотеки	5
5 Инфраструктура и форматы	5
6 Хранение и воспроизводимость	6
7 Дополнительные возможности и развитие	7

1 Общие сведения

Исходный код: <https://github.com/kolloko2/112-ai-trainer>, версия 9fb10f8. Приложение состоит из Python-сервисов, браузерного интерфейса на JavaScript, локальной АТС и файловых ресурсов. Контейнеры собираются из Dockerfile проекта. Ollama работает на локальном хосте и доступен серверным компонентам.

Устройство языковой модели задаётся параметром LLM_DEVICE: auto (по умолчанию — видеокарта при наличии, иначе CPU), cpu (num_gpus=0, минимальный сервер по ТЗ) или gpu (все слои на видеокарте). Речевые модели исполняются локальными CPU-провайдерами. Для использования продукта не нужны API-ключи сторонних поставщиков ИИ. Сохранённый в исходниках адаптер OpenRouter является альтернативной ветвью разработки и выключен в описанной конфигурации.

2 Функциональная архитектура

Браузер обращается к Frontend по HTTPS. Frontend обслуживает файлы интерфейса и проксирует разрешённые запросы Backend и Voice. Backend проверяет роль и принадлежность данных, хранит версии сценариев, события и оценки. Voice управляет аудиотрактором и соединяется с Asterisk через ARI и WebSocket media.

LLM получает роль собеседника, текущие доступные факты и ограниченную историю. Будущие доклады и приватные эталоны не должны попадать в контекст ученика. Изменение статусов и оценка решений выполняются серверными правилами, а не произвольной командой языковой модели.

Каталог	Ответственность
backend	Учебная логика, модели данных, оценка, API и доступ
frontend	HTML, CSS, JavaScript и сервер интерфейса
voice/app	Состояния звонков, аудио, провайдеры речи и обмен событиями

Каталог	Ответственность
deploy	Контейнеры, TLS, резервирование и операции
shared/api	Контракты OpenAPI и AsyncAPI
tools	Импорт, подготовка ресурсов, демонстрация и проверки

3 Языковые и речевые модели

Компонент	Рабочий вариант	Назначение
Телефонный диалог	Qwen3 4B Instruct 2507 Q4_K_M	Короткий ответ собеседника по фактам
Авторинг и разбор	qwen3:8b, профиль standard	Сценарии, эталоны и аналитические пояснения
Предварительное распознавание	Vosk small ru 0.22	Локальная обработка русской речи
Финальное распознавание	GigaAM v2 CTC через sherpa-onnx, INT8	Уточнение результата распознавания
Синтез	Silero v5_5_ru, голос baya	Русская речь локально на CPU
Морфология	py morphology3	Локальный анализ словоформ и проверок текста
OCR	Tesseract rus и eng	Извлечение текста из изображений документов

Для телефонной модели установлен контекст 4096 токенов, максимум 120 выходных токенов, температура 0,2 и шесть CPU-потоков на измеренном шестиядерном хосте в режиме CPU. Инструкции ограничивают ответ короткой русской репликой. Модель Instruct не использует длинный режим рассуждений в этом профиле.

Квантование Q4_K_M уменьшает объём весов телефонной LLM; установленный файл занимает примерно 2,5 ГБ, прогретый процесс модели на стенде — около 3,2 ГБ. GigaAM использует отдельный INT8 ONNX-файл. Нельзя переносить эти значения на всю оперативную память комплекса: другие модели, сервисы и буферы требуют собственных ресурсов.

4 Основные библиотеки

Библиотека или средство	Применение
FastAPI, Uvicorn	HTTP API и жизненный цикл Python-сервисов
Pydantic, pydantic-settings	Проверка схем и конфигурации
HTTPX, websockets	Межсервисные запросы и потоки событий
psycopg	Доступ к PostgreSQL
python-dotenv	Чтение локальной конфигурации
ldap3	Проверка учётных данных каталога по LDAPS
openpyxl	XLSX, классификаторы и загрузки
pypdf, pypdfium2	Чтение PDF и подготовка страниц для OCR
ReportLab	Формирование PDF-отчётов и сертификатов
Pillow	Обработка документных изображений
NumPy	Представление и обработка аудиоданных
Vosk, sherpa-onnx	Локальное распознавание
PyTorch	Исполнение модели Silero
cryptography	Шифрование резервных архивов
pytest, pytest-asyncio	Автоматические проверки Python
Playwright	Проверки браузерных сценариев

Piper поддерживается как альтернативный локальный синтезатор, но в измеренном профиле выбран Silero. Полный перечень установленных Python-пакетов с версиями включён в файл `technology_inventory.json` рядом с документами; он дополняет прямые зависимости `backend/requirements.txt`, `frontend/requirements.txt`, `voice/pyproject.toml` и `deploy/requirements.txt`.

5 Инфраструктура и форматы

Используются Docker Compose, PostgreSQL 16, Asterisk 22.11.0, Ollama и OpenSSL. Дополнительный профиль балансировки использует HAProxy;

тестовый каталог — OpenLDAP. Каталог организации подключается по его адресу и параметрам LDAPS.

Интерфейс или формат	Использование
REST /api/v1	Аккаунты, задания, карточки, оценка и администрирование
WebSocket /ws/v1	События диалога и взаимодействие с голосом
OpenAPI и AsyncAPI	Машиночитаемые контракты
JSON	Сценарии, эталоны, события, экспорт и API
XML	Импорт и экспорт поддерживаемых настроек и материалов
CSV и XLSX	Статистика и табличный обмен
PDF и DOCX	Отчёты, сертификаты и методические материалы
WAV и аудиозаписи	Учебные разговоры и проверочные записи
TLS, WSS, SRTP	Защищённые сетевые соединения профиля

XML-обмен охватывает определённые схемы приложения. Он не объявляется универсальной совместимостью со всеми внешними форматами Системы-112. CSV/XLSX защищают текстовые значения от интерпретации как формул при выгрузке.

6 Хранение и воспроизводимость

Основные данные находятся в PostgreSQL; аудио и служебные очереди — в постоянных томах. Карта использует отдельный SQLite-пакет только как картографический ресурс, не как замену основной БД. Секреты передаются через окружение и не входят в образ или Git.

Для воспроизводимой поставки фиксируют коммит, хеши контейнерных образов, файлы и контрольные суммы моделей и карты, версии зависимостей и конфигурационный профиль. Диапазоны версий в requirements задают допустимые зависимости, а снимок установленной среды фиксирует конкретный стенд.

Лицензии кода, моделей, шрифтов и карты рассматриваются отдельно. При передаче весов необходимо сохранить сопровождающие лицензионные файлы. Каждая модель поставляется со своей лицензией. Для данных OpenStreetMap сохраняется атрибуция источника.

7 Дополнительные возможности и развитие

Новые упражнения добавляются через версию библиотеку. Для новых служб расширяются справочник, классификатор, получатели территории и профиля, а затем проверяются сценарии. Не следует жёстко привязывать алгоритм к одной ДДС.

Телефонная модель меняется через PHONE_LLM_MODEL после проверки роли, фактов и задержек. Увеличение контекста повышает стоимость обработки; сначала целесообразно сокращать повторные доклады и несущественную историю. Увеличение числа потоков CPU требует измерения, поскольку STT и TTS используют тот же процессор.

Переключение CPU/GPU выполняется параметром LLM_DEVICE без изменения кода; замеры обоих режимов — в T112 ПД 08. Расширение количества голосовых узлов требует маршрутизации звонков и состояния Voice; увеличение числа Backend-реплик само по себе не увеличивает пропускную способность модели.