

112 AI Trainer

Тренажёр диспетчера ДДС

Протокол измерений и направления повышения эффективности

Т112 ПД 08

Программная версия v1.0

Разработчик и ответственный за документацию

Кодзаев Николай Петрович

28.09.2026



Аннотация

Документ фиксирует измеренные задержки локального диалога на CPU и GPU и выполненные проверки программной версии. Отдельно приведены расчётные варианты модернизации. Расчёт модернизации приведён отдельно от замеров.

Содержание

1 Объект и условия измерения	3
2 Результат полного голосового упражнения	3
3 Изменения для ускорения	4
4 Сравнение вариантов	4
5 Другие измерения и проверки	5
6 Видеокарта и процессор	5
7 Порядок повторения и исходные данные	6

1 Объект и условия измерения

Контрольный стенд: AMD Ryzen 5 5600, шесть физических ядер и двенадцать логических потоков, 32 ГБ RAM, Windows и Docker Desktop, Ollama 0.34.4. Телефонная модель — qwen3:4b-instruct-2507-q4_K_M. Контекст 4096, шесть потоков CPU, num_gpu=0. Ollama показывал 100% CPU и около 3,2 ГБ памяти модели.

Использовались синтетические учебные сведения. Все вычисления модели, распознавания и синтеза выполнялись локально. Время загрузки весов не включалось в замер прогретого ответа. Во время сравнительных проб GPU был отключён для инференса; результаты GPU-тестов в этот протокол не включены.

Измеряются разные интервалы: генерация модели; обработка речевого хода Voice; длительность произнесённой реплики; длительность упражнения. Эти показатели нельзя сравнивать между собой как одну «задержку звонка».

2 Результат полного голосового упражнения

В финальном проходе завершены пять SIP-звонков: первоначальный доклад дежурному и четыре оперативных доклада. Четыре уточняющих вопроса распознаны, ответы воспроизведены. Карточка и занятие завершены, отчёт преподавателя получен.

Генерация	Время модели в секундах	Выходных токенов
Подтверждение доклада	3,470	36
Уточнение выезда	6,004	45
Уточнение прибытия	6,370	48
Уточнение работ	8,283	64
Уточнение результата	9,239	61

Среднее время модели — 6,673 секунды, медиана — 6,370 секунды. Все пять ответов завершены штатно, без модельного таймаута. Интервал метрики `total_turn_latency_ms` для этих ходов составил 5,022–10,731 секунды. Он не включает полную длительность последующего прослушивания реплики.

Суммарно сгенерировано 254 выходных токена за 33,366 секунды запросов: эффективная скорость около 7,61 токена в секунду с учётом обработки входа и накладных расходов. Четыре быстрых ответа по правилу о пострадавших исключены из статистики LLM.

Итог учебного оценивания — 91,67%, 11 из 12 проверок, без критических ошибок. Голосовой цикл пройден полностью.

3 Изменения для ускорения

Телефонная модель отделена от модели авторинга. Удалены повторные чтения уже переданного доклада из контекста, сохранены исходные факты и последние шесть реплик. Управляющие инструкции сокращены; произносимый текст и адреса остаются русскими. Лимит выхода действительно передаётся провайдеру.

Исправлен прогрев: запрос идёт на настроенный `OLLAMA_URL`, а не на `localhost` контейнера. Веса удерживаются в памяти. Общий предел ожидания телефонной модели установлен в 15 секунд, включая корректирующий повтор роли в режиме 112.

Модель не управляет оценками и не открывает статусы. При недоступности генерации применяется предусмотренный ответ по доступным фактам. Сведения о пострадавших сверяются с фактами сценария.

4 Сравнение вариантов

Вариант	Наблюдение при выборе
Прежняя Qwen3 4B	На четырёх исходных вопросах 7,5–30,2 с

Вариант	Наблюдение при выборе
Qwen3 1.7B Q4	Быстрее, но допускала смену роли и постороннюю оценку ученика
Qwen3.5 2B Q8	В первом наборе около 9–12 с, неудачные уточнения
Qwen3.5 2B Q4	4,1–9,6 с, смешение языков и повторения
Qwen3 4B Instruct Q4	Выбрана по сочетанию скорости и соблюдения роли

В дополнительном наборе из 11 запросов выбранная модель дала ответы за 1,330–13,940 секунды без таймаута. Варианты запускались с разными промптами, числом потоков и историей.

5 Другие измерения и проверки

После изменений выполнены 355 тестов Backend, прокси и подготовки развёртывания; три теста пропущены. Отдельно выполнены 56 тестов Voice. Синтаксис изменённых JavaScript-файлов проверен.

В отдельном замере синтеза пакет из 20 реплик после прогрева обрабатывался за 4,449 секунды одним процессом и за 2,980 секунды двумя процессами. Это ускорение примерно в 1,49 раза. Измерялось время синтеза пакета из 20 реплик.

Контрольный запрос геометрии карты после изменения плана выборки занимал 1,009 секунды вместо 4,564–4,791 секунды. Замер выполнен для контрольного запроса геометрии. Источник: docs/ACCEPTANCE_2026-09-27.md.

Авторинг использует отдельный длительный бюджет генерации. Телефонный лимит 15 секунд применяется к разговору.

6 Видеокарта и процессор

Устройство языковой модели выбирается параметром «Устройство модели» (LLM_DEVICE) без изменения кода: авто, только CPU, видеокарта.

Замер 27.09.2026: qwen3:4b-instruct-2507-q4_K_M, свободная реплика бригады, 80 токенов, после прогрева, три прогона.

Режим	Время ответа модели
Видеокарта RTX 5060 Ti 8 ГБ (авто или GPU)	0,40–0,48 с
Процессор, шесть потоков (CPU)	1,85–3,22 с
Типовые ходы доклада (без модели)	около 0,2 с

Типовые ходы — принятие сведений, уточнение недостающего факта, подтверждение приёма — обрабатываются правилами и не ждут модель. Оценка действий детерминирована и от устройства не зависит.

7 Порядок повторения и исходные данные

CPU-пробы повторяются `tools/benchmark_phone_cpu.py`; реальный голосовой цикл — `tools/acceptance_dds_sip.py --followups`. Второй инструмент создаёт синтетическое занятие и использует отдельный телефонный номер, поэтому его запускают только после согласования окна проверки.

В комплект включён файл `measurements.json` с числовыми результатами и условиями. Исходные локальные материалы проверки: `artifacts/cpu-phone-2026-09-27/sip-final2/result.json` и `final-controlled.json`. Записи разговоров, токены сессий и полные технические журналы в открытый документ не переносятся.

Критерий повторения: указать оборудование, версии, модель, число потоков, состояние прогрева и фоновые процессы; записать каждую задержку, число токенов, ошибки и условия завершения. Нельзя сравнивать холодный первый запрос одного варианта с прогретым запросом другого без отдельного обозначения.