

112 AI Trainer

Тренажёр диспетчера ДДС

Протокол измерений и направления повышения эффективности

Т112 ПД 08

Программная версия v1.0

Разработчик и ответственный за документацию

Кодзаев Николай Петрович

28.09.2026



Аннотация

Документ фиксирует измеренные задержки локального диалога на CPU и GPU и выполненные проверки программной версии. Отдельно приведены расчётные варианты модернизации. Расчёт модернизации приведён отдельно от замеров.

Содержание

1 Объект и условия измерения	3
2 Результат полного голосового упражнения	3
3 Изменения для ускорения	4
4 Сравнение вариантов	4
5 Другие измерения и проверки	5
6 Голосовой цикл на видеокарте	5
7 Видеокарта и процессор	6
8 Порядок повторения и исходные данные	6

1 Объект и условия измерения

Контрольный стенд: AMD Ryzen 5 5600, шесть физических ядер и двенадцать логических потоков, 32 ГБ RAM, Windows и Docker Desktop, Ollama 0.34.4. Телефонная модель — qwen3:4b-instruct-2507-q4_K_M. Контекст 4096, шесть потоков CPU, num_gpu=0. Ollama показывал 100% CPU и около 3,2 ГБ памяти модели.

Использовались синтетические учебные сведения. Все вычисления модели, распознавания и синтеза выполнялись локально. Время загрузки весов не включалось в замер прогретого ответа. Во время сравнительных проб GPU был отключён для инференса; результаты GPU-тестов в этот протокол не включены.

Измеряются разные интервалы: генерация модели; обработка речевого хода Voice; длительность произнесённой реплики; длительность упражнения. Эти показатели нельзя сравнивать между собой как одну «задержку звонка».

2 Результат полного голосового упражнения

В финальном проходе завершены пять SIP-звонков: первоначальный доклад и четыре оперативных доклада. Четыре уточняющих вопроса распознаны, ответы воспроизведены. Карточка и занятие завершены, отчёт преподавателя получен.

Генерация	Время модели в секундах	Выходных токенов
Подтверждение доклада	3,470	36
Уточнение выезда	6,004	45
Уточнение прибытия	6,370	48
Уточнение работ	8,283	64
Уточнение результата	9,239	61

Среднее время модели — 6,673 секунды, медиана — 6,370 секунды. Все пять ответов завершены штатно, без модельного таймаута. Интервал метрики `total_turn_latency_ms` для этих ходов составил 5,022–10,731 секунды. Он не включает полную длительность последующего прослушивания реплики.

Суммарно сгенерировано 254 выходных токена за 33,366 секунды запросов: эффективная скорость около 7,61 токена в секунду с учётом обработки входа и накладных расходов. Четыре быстрых ответа по правилу о пострадавших исключены из статистики LLM.

Итог учебного оценивания — 91,67%, 11 из 12 проверок, без критических ошибок. Голосовой цикл пройден полностью.

3 Изменения для ускорения

Телефонная модель отделена от модели авторинга. Удалены повторные чтения уже переданного доклада из контекста, сохранены исходные факты и последние шесть реплик. Управляющие инструкции сокращены; произносимый текст и адреса остаются русскими. Лимит выхода действительно передаётся провайдеру.

Исправлен прогрев: запрос идёт на настроенный `OLLAMA_URL`, а не на `localhost` контейнера. Веса удерживаются в памяти. Общий предел ожидания телефонной модели установлен в 15 секунд, включая корректирующий повтор роли в режиме 112.

Модель не управляет оценками и не открывает статусы. При недоступности генерации применяется предусмотренный ответ по доступным фактам. Сведения о пострадавших сверяются с фактами сценария.

4 Сравнение вариантов

Вариант	Наблюдение при выборе
Прежняя Qwen3 4B	На четырёх исходных вопросах 7,5–30,2 с

Вариант	Наблюдение при выборе
Qwen3 1.7B Q4	Быстрее, но допускала смену роли и постороннюю оценку ученика
Qwen3.5 2B Q8	В первом наборе около 9–12 с, неудачные уточнения
Qwen3.5 2B Q4	4,1–9,6 с, смешение языков и повторения
Qwen3 4B Instruct Q4	Выбрана по сочетанию скорости и соблюдения роли

В дополнительном наборе из 11 запросов выбранная модель дала ответы за 1,330–13,940 секунды без таймаута. Варианты запускались с разными промптами, числом потоков и историей.

5 Другие измерения и проверки

После изменений выполнены 355 тестов Backend, прокси и подготовки развёртывания; три теста пропущены. Отдельно выполнены 56 тестов Voice. Синтаксис изменённых JavaScript-файлов проверен.

В отдельном замере синтеза пакет из 20 реплик после прогрева обрабатывался за 4,449 секунды одним процессом и за 2,980 секунды двумя процессами. Это ускорение примерно в 1,49 раза. Измерялось время синтеза пакета из 20 реплик.

Контрольный запрос геометрии карты после изменения плана выборки занимал 1,009 секунды вместо 4,564–4,791 секунды. Замер выполнен для контрольного запроса геометрии.

Авторинг использует отдельный длительный бюджет генерации. Телефонный лимит 15 секунд применяется к разговору.

6 Голосовой цикл на видеокarte

Сквозная проверка по SIP с синтезированной речью ученика: доклад бригаде, вопросы по каждому из четырёх докладов о ходе работ, все статусы и завершение карточки. Стенд: RTX 5060 Ti 8 ГБ, режим «Устройство модели» — авто.

Показатель	Результат
Звонков	5, все распознаны и завершены
Оценка действий ДДС	100 %
От конца фразы ученика до первого звука ответа	1,4–2,0 с
Ответ модели на свободный вопрос	0,75–0,97 с
Ответ по правилам (типовой ход)	20–70 мс

7 Видеокарта и процессор

Устройство языковой модели выбирается параметром «Устройство модели» (LLM_DEVICE) без изменения кода: авто, только CPU, видеокарта. Замер 27.09.2026: qwen3:4b-instruct-2507-q4_K_M, свободная реплика бригады, 80 токенов, после прогрева, три прогона.

Режим	Время ответа модели
Видеокарта RTX 5060 Ti 8 ГБ (авто или GPU)	0,40–0,48 с
Процессор, шесть потоков (CPU)	1,85–3,22 с
Типовые ходы доклада (без модели)	около 0,2 с

Типовые ходы — принятие сведений, уточнение недостающего факта, подтверждение приёма — обрабатываются правилами и не ждут модель. Оценка действий детерминирована и от устройства не зависит.

8 Порядок повторения и исходные данные

CPU-пробы повторяются tools/benchmark_phone_cpu.py; реальный голосовой цикл — tools/acceptance_dds_sip.py --followups. Второй инструмент создаёт синтетическое занятие и использует отдельный телефонный номер, поэтому его запускают только после согласования окна проверки.

В комплект включён файл measurements.json с числовыми результатами и условиями. Исходные локальные материалы проверки: artifacts/cpu-phone-

2026-09-27/sip-final2/result.json и final-controlled.json. Записи разговоров, токены сессий и полные технические журналы в открытый документ не переносятся.

Критерий повторения: указать оборудование, версии, модель, число потоков, состояние прогрева и фоновые процессы; записать каждую задержку, число токенов, ошибки и условия завершения. Нельзя сравнивать холодный первый запрос одного варианта с прогретым запросом другого без отдельного обозначения.